

Uniwersytet Jagielloński w Krakowie

Wydział Fizyki, Astronomii i Informatyki
Stosowanej

Łukasz Wójcik

Nr albumu: 1188524

**Opracowanie jedno-
i wielomodalnych modeli
predykcji emocji**

Praca magisterska
na kierunku Informatyka Stosowana

Praca wykonana pod kierunkiem:
dr inż. Krzysztofa Kutta
Zakład Technologii Gier

Kraków 2023

Abstract

Automatic emotions predictions steadily gains more and more popularity. There are numerous potential use cases in robotics, entertainment, teaching and many more. The development of machine learning and increasing availability of better and better datasets enables new attempts at creating systems capable of predicting emotions. This thesis outlines the most important aspects of emotions relevant to the topic. Starting with possible sources which give information about emotional state, like facial expression, speech or biosignals, and finishing with representations of emotions in a computer system. Next the basics of machine learning are presented, followed by more in-depth explanation of support vector machines, random forests and neural networks. Finally, three models for automatic prediction of four, six and eight emotions based on electrocardiography and electrodermal activity are proposed.

Keywords: automatic emotions prediction, affective computing, machine learning, neural networks

Abstrakt

Automatyczne rozpoznawanie emocji staje się coraz popularniejszym kierunkiem badań. Znajduje potencjalne zastosowania w robotyce, przemyśle rozrywkowym, nauce i wielu innych. Rozwój uczenia maszynowego oraz dostępność coraz lepszych zbiorów danych pozwala na próby tworzenia modeli predykcji emocji. W niniejszej pracy przedstawiono istotne informacje dotyczące emocji, źródła, na podstawie których można je rozpoznawać oraz ich reprezentację w systemach komputerowych. Następnie omówiono podstawy uczenia maszynowego, z naciskiem na maszyny wektorów nośnych, lasy losowe oraz sieci neuronowe. Na koniec stworzono trzy modele, które przewidują cztery, sześć oraz osiem emocji na podstawie cech uzyskanych z elektrokardiografii i reakcji skórno-galwanicznej.

Słowa kluczowe: automatyczna predykcja emocji, informatyka afektywna, uczenie maszynowe, sieci neuronowe

Spis treści

Wstęp	4
1 Automatyczna predykcja emocji	5
1.1 Uogólniony system rozpoznawania emocji	5
1.2 Metody rozpoznawania emocji	6
1.2.1 Wyraz twarzy	7
1.2.2 Postawa ciała i gestykulacja	8
1.2.3 Mowa	9
1.2.4 Sygnały biofizyczne	10
1.3 Reprezentacja emocji w systemie komputerowym	12
1.4 Modalność w modelach predykcji emocji	14
1.5 Podsumowanie	15
2 Uczenie maszynowe	16
2.1 Podstawy uczenia maszynowego	16
2.1.1 Rodzaje uczenia maszynowego	16
2.1.2 Przeuczenie i niedouczenie	17
2.2 Przykładowe algorytmy uczenia maszynowego	18
2.2.1 Drzewa decyzyjne i lasy losowe	18
2.2.2 Maszyna wektorów nośnych	20
2.3 Sztuczne sieci neuronowe	21
2.3.1 Głębokie sieci neuronowe	21
2.3.2 Funkcje aktywacji	22
2.3.3 Gradient descent	23
2.4 Podsumowanie	24
3 Część praktyczna	25
3.1 Zbiór danych	25
3.2 Przygotowanie danych	26
3.2.1 Oczyszczanie i ekstrakcja cech	26
3.2.2 Grupowanie	27
3.3 Wyniki	28

3.3.1	Elektrokardiografia	29
3.3.2	Reakcja skórno-galwaniczna	30
3.3.3	System wielomodalny	30
3.4	Podsumowanie wyników	31
Podsumowanie		32
Bibliografia		36
Spis rysunków		38
Spis tabel		39

Wstęp

Emocje są nieodłączną częścią ludzkiego życia. Stanowią bardzo ważny element komunikacji niewerbalnej, wpływają na zachowanie i postrzeganie świata. Możliwość rozpoznawania emocji, reagowanie na nie oraz ich wywoływanie pozwoliłoby na rozwój w wielu dziedzinach. Do najważniejszych należą robotyka, zwłaszcza interakcja człowiek-robot, marketing, szkolnictwo, przemysł rozrywkowy. Doprowadziło to do powstania interdyscyplinarnej nauki pod nazwą informatyka afektywna (ang. *affective computing*), która łączy elementy informatyki, psychologii, neurologii, inżynierii i wielu innych.

Rozwój technologiczny pozwala na podejmowanie prób automatycznego rozpoznawania emocji przy pomocy systemów komputerowych. Algorytmy uczenia maszynowego potrafią przetwarzać bardzo zróżnicowane źródła informacji o emocjach. Coraz mniejsze rozmiary sensorów i większa dokładność pozwalają na rejestrowanie przeróżnych parametrów: wyraz twarzy, sposób mowy, a nawet sygnały biofizyczne, takie jak EKG lub EEG.

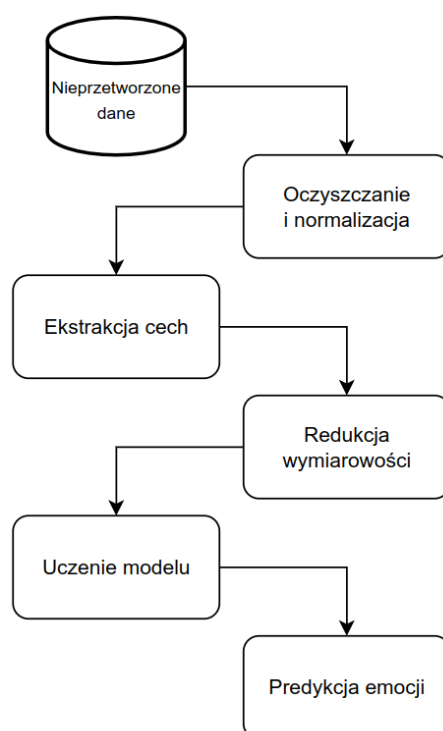
Celem pracy jest wykorzystanie istniejącego zbioru zawierającego zapisy elektrokardiografii oraz reakcji skórno-galwanicznej i stworzenie systemu, który będzie w stanie dokonywać predykcji emocji. W tym celu zaprojektowane zostanie kilka modeli, z wykorzystaniem różnych algorytmów uczenia maszynowego. Następnie wykonane zostanie porównanie osiągniętych wyników.

Rozdział 1

Automatyczna predykcja emocji

1.1 Uogólniony system rozpoznawania emocji

W badaniach nad automatycznym rozpoznawaniem emocji dominują systemy oparte na uczeniu maszynowym lub modelach statystycznych [1, 2]. Powoduje to, że wykonuje się w nich podobne kroki. Dane w takich systemach przechodzą zazwyczaj sekwencyjnie przez tak zwany potok (ang. *pipeline*) [3].



Rysunek 1.1: Ogólny schemat systemu predykcji emocji

Rysunek 1.1 przedstawia uproszczony schemat systemu predykcji emocji. Na początku system otrzymuje nieprzetworzone dane, często nazywane surowymi (ang. *raw*

data). W zależności od źródła mogą to być zdjęcia, filmy, zapisy sygnałów biofizycznych (elektrokardiografia, elektroencefalografia itp.) oraz wiele innych. Są to wartości pochodzące bezpośrednio z sensorów, bazy danych lub publicznie dostępnych zbiorów [1, 4].

Dane wejściowe zazwyczaj nie są wystarczającej jakości dlatego kolejny krok to ich oczyszczanie. Może to być na przykład redukcja szumów w sygnale, odrzucanie skrajnych wartości lub uzupełnianie brakujących. Dodatkowo niektóre modele dają lepsze wyniki po normalizacji danych [3].

Większość modeli nie przyjmuje na wejściu surowych danych, dlatego następnie wykonuje się proces ekstrakcji cech (ang. *feature extraction*). Pozwala on na zmianę danych wejściowych na wartości istotne dla rozpoznawania emocji. Często są to wartości z funkcji i miar statystycznych, takie jak mediana, średnie, odchylenia itp. Przykładowe cechy to geometria twarzy, szybkość mówienia, czas pomiędzy uderzeniami serca [5].

W zależności od metody ilość cech może wynosić ponad 700 [6], dlatego w niektórych systemach kolejnym krokiem jest redukcja wymiarowości. Ma ona na celu zmniejszenie liczby cech wejściowych poprzez łączenie tych silnie skorelowanych, rzutowanie w mniej wymiarowe przestrzenie lub odrzucanie wartości, które nie poprawiają wyników. Powszechnie stosowane podejścia to: analiza głównych składowych (ang. *principal components analysis (PCA)*), grupowanie hierarchiczne (ang. *hierarchical cluster analysis (HCA)*), Gaussian random projection [3].

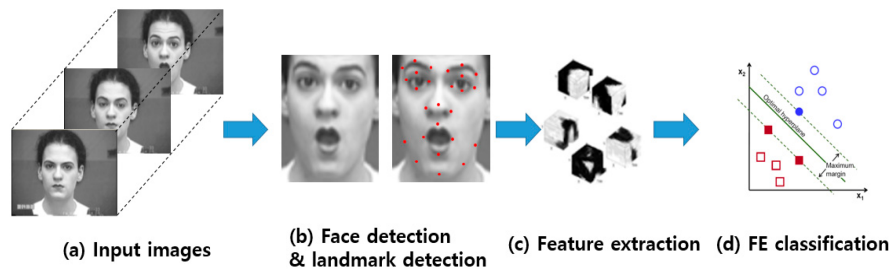
Po uzyskaniu ostatecznych danych następuje trening modelu, zazwyczaj jest to uczenie nadzorowane [4]. Oznaczanie danych odbywa się na dwa sposoby. W pierwszym każdy wektor danych ma przypisaną kategorię emocji, na przykład strach lub złość. W drugim emocje opisane są w przestrzeni wielowymiarowej, zatem zamiast jednej kategorii posiadają zazwyczaj dwie lub trzy wartości. Do klasyfikacji stosuje się różnorakie podejścia, między innymi: support vector machine (SVM), random forest classifier (RFC), stochastic gradient descent (SGD), AdaBoost, k-nearest neighbor (k-NN), hidden Markov models (HMM), linear discriminate analysis (LDA), sztuczne sieci neuronowe [1, 2, 7].

1.2 Metody rozpoznawania emocji

Istnieje wiele sposobów, na podstawie których można wnioskować stan emocjonalny człowieka. Pozwala to na wykorzystanie bardzo zróżnicowanych podejść, od oceny wyglądu, przez analizę zachowań, aż po pomiary aktywności elektrycznej w organizmie. Poniżej znajduje się opis najczęściej stosowanych metod [1, 2], ich wady oraz zalety.

1.2.1 Wyraz twarzy

Ludzka twarz jest bardzo znaczącym źródłem informacji i odgrywa dużą rolę w komunikacji niewerbalnej. Na jej podstawie można oceniać między innymi: płeć, wiek, pochodzenie etniczne, czy stan emocjonalny [5]. Dzięki temu twarz jest bardzo popularnym źródłem w automatycznym rozpoznawaniu emocji, z początkami prac sięgającymi lat 90. XX wieku [5].



Rysunek 1.2: Schemat systemu rozpoznającego emocje na podstawie twarzy.

Źródło: [7]

Rysunek 1.2 przedstawia ogólny schemat systemu rozpoznającego emocje na podstawie wyrazu twarzy. Na wejściu program otrzymuje pojedyncze zdjęcie lub nagranie zawierające twarz. Pierwszym krokiem jest wykrycie twarzy. W dostarczonym źródle może być ich wiele. Następnie przeprowadza się proces ekstrakcji charakterystycznych miejsc. Po uzyskaniu danych o twarzy zostają one przetworzone przez algorytm uczenia nadzorowanego [5].

Jedno z popularnych podejść rozpoznaje emocje na podstawie Facial Action Coding System (FACS) [8]. Zbiór ten zawiera, w zależności od wersji, od 33 do 44 tak zwanych Action Units (AU). Powstały one przy pomocy stymulacji elektrycznej mięśni twarzy, które biorą udział w wyrażaniu emocji. Dzięki temu uzyskano obiektywne ruchy mięśni o różnej intensywności zależnej od napięcia prądu. Sam zbiór nie zawiera ścisłego określenia połączeń AU i odpowiadającym im emocjom, a jedynie hipotezy [5]. Rysunek 1.3 przedstawia przykładowe Action Units.

AU1	AU2	AU5	AU9	AU15	AU23	AU25	AU27
Inner Brow Raiser	Outer Brow Raiser	Upper Lid Raiser	Nose Wrinkler	Lip Corner Depressor	Lip Tightener	Lip Parts	Mouth Stretch

Rysunek 1.3: Action Units w trzech częściach twarzy. Źródło: [7]

Inne podejścia bazują na zbiorach, w których osoby były proszone o wyrażenie danej emocji. Pozyskane w ten sposób dane mają jednak wadę w postaci zbyt inten-

sywnego wyrazu twarzy, w dodatku opartych na stereotypach. Osoba poproszona o to, aby pokazała zdziwienie, zazwyczaj wygląda zupełnie inaczej, niż gdy jest naprawdę zdziwiona. Nawet dobrze wyszkolony aktor nie jest w stanie dokładnie odwzorować naturalnej reakcji [5]. Powoduje to, że modele szkolone na takich zbiorach nie są w stanie rozpoznawać emocji wyrażanych w sposób „normalny”. Jedną z możliwości zapobiegania temu zjawisku jest tworzenie zbiorów, w których emocje są wywoływane przez prawdziwe zdarzenia, a nie odgrywane przez aktorów [5].

Główną zaletą rozpoznawania emocji na podstawie twarzy jest stosunkowa prostota, aparaty są tanie i powszechnie dostępne. Dodatkowo zbieranie danych nie wymaga kontaktu fizycznego i nie powoduje dyskomfortu. Same wyrazy twarzy dla wielu emocji są uniwersalne między członkami różnych kultur, płci i niezależne od wieku [5].

Mimo to z tym podejściem wiąże się wiele problemów. Począwszy od trudności wynikających z samego rozpoznawania twarzy, na przykład różne oświetlenie, czy kąt, pod jakim się ona znajduje. Następnie pojawiają się problemy związane z stanami emocjonalnymi: istnieje możliwość, że osoba nie wyraża żadnych emocji lub mogą być one bardzo nikłe [5].


1.2.2 Postawa ciała i gestykulacja

Drugim bardzo ważnym źródłem informacji o emocjach jest postawa ciała człowieka, jego gesty lub ich brak. Stanowią one znaczną część komunikacji niewerbalnej, ruch dłoni jest drugim co do wielkości źródłem, mówiącym o stanie emocjonalnym, więcej informacji pochodzi jedynie z wyrazu twarzy [9]. Co więcej, postawa ciała pomaga w zmaganiu się z aktualnie odczuwanymi emocjami [10].

Jednym z powszechnie stosowanych sposobów śledzenia ruchu ciała są kamery termowizyjne [5]. Pomiary są możliwe dzięki odbłaskowym płytkom, które umieszczane są na odzieży. Pozwala to na zapis ruchu w trójwymiarowej przestrzeni. Tego typu podejście wymaga jednak noszenia specjalnego stroju, a dokładność jest zależna od ilości znaczników. Z tego powodu mierzenie ruchu dłoni, a zwłaszcza palców jest problematyczne. Z drugiej strony zbieranie jest mniej danych, a ich przetwarzanie jest łatwiejsze. Dodatkowo zapewniona jest anonimowość badanych [5].

Dzięki rozwojowi widzenia maszynowego możliwe stało się również używanie zwykłych kamer. Takie podejście zapewnia większą swobodę, nie wymaga specjalnego stroju. Co najważniejsze pozwala na dokładniejsze odwzorowanie ruchów, zwłaszcza palców. To podejście również musi zmagać się z problemami typowymi dla rozpoznawania obrazów: oświetlenie, kolor skóry, ubrania mogą negatywnie wpływać na dokładność [5].

Rysunek 1.4 przedstawia dwa sposoby modelowania ludzkiego ciała w systemach komputerowych. Po lewej stronie widnieje model oparty na częściach ciała (ang. *part based model*). Każda część jest rozpoznawana osobno na podstawie wiedzy o budowie ludzkiego ciała. Otrzymywana jest reprezentacja dwuwymiarowa. Po prawej stronie



Rysunek 1.4: Sposoby reprezentowania ciała w komputerze: zbiór części ciała (lewa strona) oraz reprezentacja szkieletowa (prawa strona). Źródło: [9]

przedstawiono model szkieletowy (ang. *kinematic model*). W tej reprezentacji ciało jest zbiorem wierzchołków połączonych krawędziami, przez co można je reprezentować jako graf [9]. Wierzchołki interpretowane są jako stawy, które posiadają pewne stopnie swobody, odpowiednie dla danej części ciała. Pozwala to na złożoną reprezentację w przestrzeni trójwymiarowej [5].

Po uzyskaniu reprezentacji ciała, w systemie następuje proces rozpoznawania postawy, a następnie oceny emocji. Używa się do tego zarówno statycznych obrazów, jak i nagrań ruchu [9, 10].


1.2.3 Mowa

Poza niewerbalnymi źródłami, emocje można również rozpoznawać na podstawie mowy. Ludzki głos stanowi bardzo bogate źródło informacji. Pozwala na wnioskowanie o wieku, płci, stanie emocjonalnym, osobowości, dialekcie i pochodzeniu mówcy [11].

W porównaniu do poprzednich źródeł mowa jest o wiele bardziej podatna na zakłócenia, szum, hałasy w tle. Wymaga więc dokładniejszego procesu oczyszczania. Bardzo ważna jest również normalizacja danych. Zakres podstawowej częstotliwości głosu, który wynosi około 50 — 500 Hz, jest o wiele większy niż różnica między wypowiedzią neutralną i w stanie złości, czyli około 68 Hz [5].

Po oczyszczeniu i normalizacji następuje proces ekstrakcji cech niskiego poziomu (ang. *low-level descriptors (LLD)*). Są to wartości oparte o częstotliwość głosu oraz o zmiany w sposobie wypowiedzi (na przykład szybkość mówienia lub poziom głośności). Sama ilość cech niskiego poziomu nie jest z góry określona i może być różna

w zależności od podejścia. Do najpopularniejszych LLD należą: fundamental frequency (F0), Mel-frequency cepstral coefficients (MFCCs), jitter, shimmer, harmonic-to-noise ratio oraz wartości z widma akustycznego [5, 12]. Rysunek 1.5 przedstawia przykładowe cechy niskiego poziomu.



Rysunek 1.5: Sygnał mowy z zaznaczonymi jitter i shimmer. Źródło: [13]

Po uzyskaniu cech niskiego poziomu można zastosować funkcje i miary statystyczne, takie jak średnie i odchylenia, aby otrzymać tak zwane cechy wysokiego poziomu (ang. *high-level descriptors (HLD)*) [5].


Podobnie jak wyrazy twarzy, mowa jest zależna od kultury i pochodzenia osoby. Dodatkowo wyszkolona osoba jest w stanie kontrolować wymowę w taki sposób, aby ukrywać odczuwane emocje lub udawać inne [5].

1.2.4 Sygnały biofizyczne

Emocje wywołują również zmiany, których nie da się zaobserwować za pomocą wzroku lub słuchu. Różne stany emocjonalne wpływają między innymi na szybkość bicia serca, wydzielanie potu, oddech, temperaturę ciała. Są to parametry, które można zmierzyć i wnioskować na ich podstawie odczuwane emocje [5].

Jednym z najpopularniejszych sposobów jest elektrokardiografia (EKG), czyli mierzenie aktywności elektrycznej serca. Do pomiarów używa się elektrod umieszczonych na skórze, najczęściej jest ich 3 lub 12. Analiza sygnału odbywa się na podstawie załameków P, Q, R, S, T [5].

Rysunek 1.6 przedstawia przykładowy sygnał EKG. Jako pierwszy występuje załamek P, który oznacza depolaryzację mięśnia przedsionków. Potem następuje zespół



Rysunek 1.6: Przykładowy sygnał EKG z zaznaczonymi załamkami. Źródło: [2]


QRS opisujący depolaryzację mięśnia komór. Po nim pojawia się załamek T odpowiadający repolaryzacji komór [2].

W automatycznym rozpoznawaniu emocji najczęściej bierze się pod uwagę zespół QRS oraz odległości między załamkami R (ang. *R-R interval / inter-beat interval*), które wykorzystuje się w analizie zmienności rytmu zatokowego (ang. *heart rate variability (HRV)*) [5].

Drugim często używanym sygnałem biofizycznym jest reakcja skórno-galwaniczna, powszechnie stosuje się dwa skróty: GSR (ang. *galvanic skin response*) lub EDA (ang. *electrodermal activity*). Opisuje ona zmiany w przewodnictwie skóry spowodowane aktywnością gruczołów potowych. Prowadzi to do różnic w wilgotności i w następstwie do zmiany oporu elektrycznego [2]. Pomiar wykonuje się za pomocą elektrod, które mogą być umieszczone w dowolnym miejscu na skórze. Zazwyczaj wykorzystuje się miejsca najbardziej czułe na zmiany emocjonalne: dłonie oraz podeszwy stóp [5].

Rysunek 1.7 przedstawia przykładowy sygnał GSR, który składa się z dwóch głównych komponentów. Szarym kolorem zaznaczono tonic component, który zmienia się powoli i zależy głównie od reakcji na czynniki środowiska (temperatura, wilgotność powietrza itp.). Na niebiesko oznaczono phasic component, przejawiający się jako krótkie piki w odpowiedzi na stan emocjonalny [2].

Poza elektrokardiografią oraz reakcją skórno-galwaniczną stosuje się również wiele innych podejść.



Rysunek 1.7: Przykładowy sygnał GSR. Czerwone linie oznaczają momenty pojawiania się stymulantu. Źródło: [2]

Fotopletyzmografia (ang. *photoplethysmography (PPG)*) jest alternatywnym sposobem mierzenia aktywności serca. Do pomiarów używa się światła, które reaguje na zmiany w ilości krwi w tkankach. Różnice w odbijanym lub przepuszczanym świetle odpowiadają uderzeniom serca [2].

Elektroencefalografia (EEG) jest używana do badania aktywności mózgu na podstawie fal δ , θ , α , β , γ . Pomiar odbywa się za pomocą elektrod umieszczonych na głowie. Zazwyczaj używa się 8, 16 lub 32 pary [2].

Elektromiografia (EMG) służy do pomiaru aktywności elektrycznej mięśni. Podczas skurczu mięśni pojawia się napięcie, które można zmierzyć na powierzchni skóry przy pomocy elektrod. EMG jest zazwyczaj stosowane dla mięśni twarzy [2].

Oddychanie jest również sygnałem biofizycznym. Pomiar wykonuje się zazwyczaj za pomocą opaski wokół klatki piersiowej, która mierzy jej ruch wywołany wdechami i wydechami [2].

Dużym problemem sygnałów biofizycznych są zakłócenia związane z aktywnością człowieka. Ruch ma duży wpływ na pracę serca, która nie zmienia się liniowo w stosunku do wysiłku. Kichnięcie powoduje w organizmie reakcję podobną do odczuwania strachu, mimo że osoba kichająca raczej nie jest przestraszona [5].

1.3 Reprezentacja emocji w systemie komputerowym

Po uzyskaniu danych należy je przypisać do odczuwanych emocji. Najprostszym sposobem jest przydzielenie im pewnej kategorii, na przykład: strach, złość, radość,

smutek itp. W automatycznym rozpoznawaniu emocji ich liczba jest zazwyczaj niewielka i wynosi od 4 do 8 [2]. Czasem są to również klasyfikatory binarne, które przewidują jedynie czy dane należą do danej klasy, czy nie.

Najczęściej wykorzystuje się kategorie należące do tak zwanych podstawowych emocji. Zostały one zaproponowane między innymi przez Paula Ekmana w 1971 roku [14]. Należą do nich: radość, smutek, złość, zdziwienie, strach oraz wstręt. Rysunek 1.8 przedstawia możliwe sposoby wyrażania tych emocji.



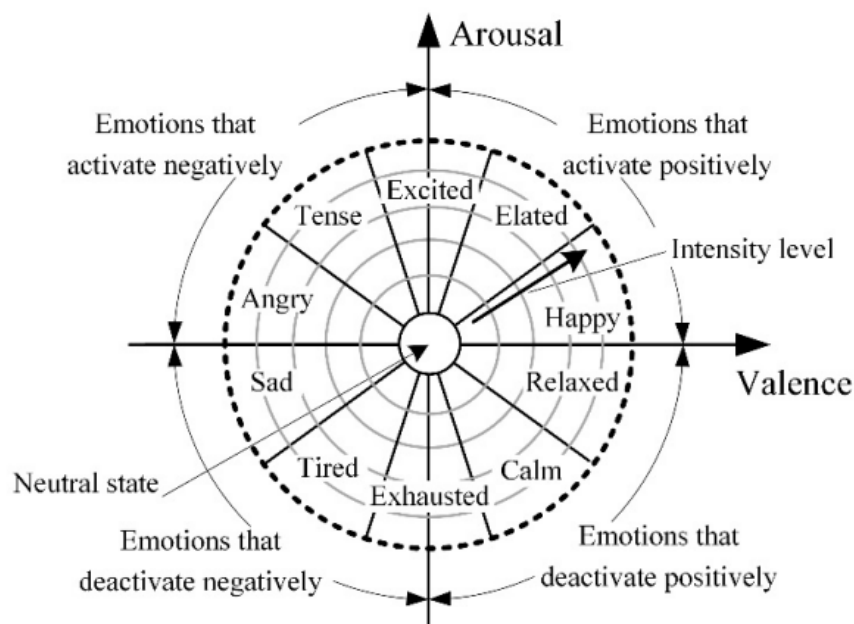
Rysunek 1.8: Przykładowa baza danych zawierająca zdjęcia twarzy przedstawiające podstawowe emocje. Źródło: [15]

Inne popularne podejścia reprezentują emocje za pomocą dwóch lub trzech ciągłych wartości liczbowych. Stany emocjonalne są przedstawione w przestrzeni, dzięki czemu można reprezentować o wiele więcej kategorii, w sposób bardziej płynny i dokładny [5].

Wiele podejść opiera się na dwuwymiarowym modelu zaproponowanym przez Jamesa Russella [16]. Emocje w tym modelu reprezentowane są za pomocą wartości opisujących przyjemność odczuwanej emocji (ang. *valence*) oraz pobudzenie jakie wywołuje (ang. *arousal*). Sam model jest zazwyczaj w kształcie koła, które może być podzielone na wycinki przedstawiające emocje. Rysunek 1.9 zawiera jedną z możliwych reprezentacji modelu Russella. Punkt leżący w danym wycinku przedstawia odpowiednią emocję [2].

Dwuwymiarowy model nie jest jednak w stanie wystarczająco rozróżniać niektóre emocje. Przykładowo strach oraz złość są reprezentowane jednakowo: przez wysokie pobudzenie i niską przyjemność. Aby poprawić rozpoznawanie stanów emocjonalnych, inne podejścia dodają trzeci wymiar utożsamiany z dominacją, jaką wywiera dana emocja [5].

Samo przypisywanie emocji do danych odbywa się za pomocą dwóch podejść [5]. Pierwsze z nich opiera się na wyszkolonych obserwatorach, którzy oceniają stan emocjonalny badanej osoby. Nie zawsze jest to jednak możliwe, dlatego drugim powszech-



Rysunek 1.9: Kołowy model oparty o torię Russella. Źródło: [2]

nie stosowanym sposobem jest samoocena. Metoda ta jest prostsza i pozwala na klasyfikację emocji w sygnałach biofizycznych. Jest jednak bardziej zawodna, ponieważ osoba może źle sklasyfikować odczuwaną emocję, lub niedokładnie ocenić moment, w którym do niej doszło [5].

1.4 Modalność w modelach predykcji emocji

Początkowo modele automatycznej predykcji emocji opierały się wyłącznie na jednym źródle informacji, były to zatem systemy jednomodalne. Ten trend był tym bardziej wzmacniany przez skupienie się na rozpoznawaniu emocji na podstawie wyrazu twarzy. Takie podejście ma jednak jedną główną wadę, system nie jest w stanie rozpoznawać emocji, gdy brakuje danych wejściowych. Zdarza się, że twarz jest zakryta, osoba nic nie mówi lub stoi nieruchomo. Aby zapobiec temu problemowi oraz przez chęć uzyskania lepszych wyników rozpoczęto prace nad systemami wykorzystującymi więcej niż jedno źródło informacji [5].

Model wielomodalny to taki, który wykorzystuje co najmniej dwa różne źródła informacji. Może to być twarz oraz mowa, gestykulacja i sygnały biofizyczne, lub wszystkie na raz. Tego typu systemy o wiele rzadziej napotykają problem braku danych oraz zapewniają lepsze wyniki [17].

Systemy wielomodalne zmagają się jednak z innymi problemami. Największy to łączenie ze sobą danych, które wymagają różnych okienek czasowych do analizy. Film

może być analizowany na podstawie pojedynczych klatek, jednak sygnały biofizyczne lub mowa wymagają zazwyczaj dłuższych pomiarów, aby dać wartościowe dane [5].

1.5 Podsumowanie

W tym rozdziale przedstawiono podstawy systemów rozpoznających emocje, ich ogólną strukturę oraz możliwe algorytmy służące do predykcji. Następnie zaprezentowane źródła, na podstawie których można wnioskować stany emocjonalne. Opisano również najczęściej uzyskiwane cechy z danych źródeł. Skupiono się na najpopularniejszych podejściach, od analizy tego, co jest odbieralne ludzkimi zmysłami: wyraz twarzy, mowa, aż po sygnały biofizyczne, wytwarzane przez organizm człowieka, niezależnie od jego woli. Dodatkowo opisano sposoby reprezentacji emocji w systemach komputerowych, modele wielowymiarowe oraz podejścia oparte o kategorie. Na koniec opisano pojęcie modalności.

Następny rozdział skupia się na uczeniu maszynowym, które jest najczęściej wykorzystywanym podejściem w systemach automatycznej predykcji emocji.

Rozdział 2

Uczenie maszynowe

2.1 Podstawy uczenia maszynowego

Klasyczne programy komputerowe składają się z szeregu instrukcji, w których zawarte są wszystkie możliwe akcje podejmowane przez użytkownika. Istnieją jednak problemy o tak dużej złożoności, że niemożliwe staje się opisanie wszystkich sytuacji. Przykładem może być autonomiczne sterowanie pojazdami. Przewidzenie wszystkich możliwych zjawisk na drodze jest bardzo trudne, jeśli nie niemożliwe. Klasyczny program musiałby być bardzo rozbudowany i złożony, a co za tym idzie również niełatwy do zrozumienia, implementacji i rozwoju. Chcemy zatem, aby taki pojazd potrafił sam podejmować decyzje nawet dla nieznanych sytuacji i uczył się na ich przykładzie.

O uczeniu maszynowym mówimy, gdy system komputerowy jest w stanie stworzyć model, który na podstawie obserwacji danych pozwala mu na tworzenie hipotez i podejmowanie decyzji [4]. Model to w rzeczywistości funkcja h , przybliżająca rzeczywistą funkcję f , która opisuje dane wejściowe. Dane te to wektory zawierające pewne cechy, na przykład: piksele w zdjęciu, częstotliwości dźwięku, ilość dni z opadami deszczu itp. W zależności od typu wartości, jakie są przewidywane, mówi się zazwyczaj o dwóch rodzajach problemów [4]:

- klasyfikacji (ang. *classification*), gdy dane wyjściowe zawierają się w skończonym zbiorze wartości,
- regresji (ang. *regression*), gdy dane wyjściowe są wartością liczbową.

2.1.1 Rodzaje uczenia maszynowego

Model uczy się dzięki zmienianiu tak zwanych parametrów. Są to wartości, które kontrolują działanie systemu, a ich ilość różni się w zależności od zastosowanego algorytmu [18]. Ponadto model uczy się na podstawie pewnej informacji zwrotnej. Rozróżnia się trzy główne podejścia [4]:

- W uczeniu nadzorowanym (ang. *supervised learning*) system uczy się na podstawie par składających się z wektora danych wejściowych i wartości, którą chcemy przewidzieć (ang. *label*). Celem uczenia jest przewidzenie wartości na podstawie danych wejściowych.
- W uczeniu nienadzorowanym (ang. *unsupervised learning*) system otrzymuje surowe dane wejściowe, w których ma wykryć pewne zależności lub wzorce. Program nie otrzymuje informacji zwrotnej, ponieważ nie istnieje pewien ściśle określony rezultat, który chcemy otrzymać.
- W uczeniu przez wzmacnianie (ang. *reinforcement learning*) uczenie odbywa się na podstawie systemu nagród i kar. Gdy system komputerowy robi to, co chcemy osiągnąć otrzymuje za to pewną nagrodę, w przeciwnym wypadku jest karany. Celem systemu jest zatem podejmowanie akcji, które prowadzą do jak największej ilości nagród.

Algorytmy uczenia maszynowego posiadają zazwyczaj również szereg tak zwanych hiperparametrów (ang. *hyperparameters*), które można traktować jako dodatkowe opcje. Nie są one zmieniane w trakcie uczenia, a wymagają ustawienia ich przed uczeniem. Mają one znaczący wpływ na osiąganе wyniki, dlatego zazwyczaj przeprowadza się osobny proces mający wybrać jak najlepsze wartości [18].


2.1.2 Przeuczenie i niedouczenie

Wystarczająco skomplikowany model jest w stanie osiągnąć bardzo dobre wyniki dla danych, na których był trenowany. Jednak głównym celem uczenia maszynowego jest stworzenie systemu, który będzie radził sobie z niezaistniałymi wcześniej wejściami. Jest to proces tak zwanej generalizacji (ang. *generalization*) [18].

To w jakim stopniu model może generalizować, zależy od jego pojemności (ang. *capacity*). Jest to miara opisująca umiejętność dopasowania modelu do różnorodnych funkcji. Model o zbyt małej pojemności nie jest w stanie dopasować się do zbioru treningowego. Z drugiej strony zbyt duża pojemność doprowadza do nauki zależności, które źle wpływają na wyniki dla nowych danych [18].

W procesie uczenia maszynowego celem jest minimalizacja błędu na zbiorze treningowym (ang. *training error*). Takie podejście może jednak doprowadzić do stworzenia modelu, który będzie wykazywał nadmierne dopasowanie (ang. *overfitting*), zwane również przeuczeniem. Powoduje to, że system nie jest w stanie poradzić sobie z danymi spoza zbioru treningowego i daje złe wyniki [18].

Chcemy zatem stworzyć model, którego celem nie będzie tylko minimalizacja błędu treningowego. Aby tego dokonać, zazwyczaj wydziela się pewien fragment ze zbioru wartości wejściowych, który zostaje użyty do oceny modelu, jest to tak zwany zbiór testowy. Nowym celem procesu uczenia jest minimalizacja błędu treningowego, ale



Rysunek 2.1: Wizualna reprezentacja wyników modelu niedouczonego (lewa strona), modelu posiadającego dobry stopień generalizacji (środek) oraz modelu przuczonego (prawa strona). Źródło: [18]

z zachowaniem jak najmniejszej różnicy między błędem treningowym a błędem testowym (ang. *test error*), który jest obliczany dla zbioru testowego [18].

Sytuację przeciwną, w której model nie jest wystarczająco skomplikowany i nie możliwe jest uzyskanie niskiego błędu treningowego, nazywa się niedouczeniem (ang. *underfitting*) [18]. Rysunek 2.1 przedstawia funkcje wygenerowane przez model niedouczony, przeuczony oraz przez odpowiednio dopasowany.

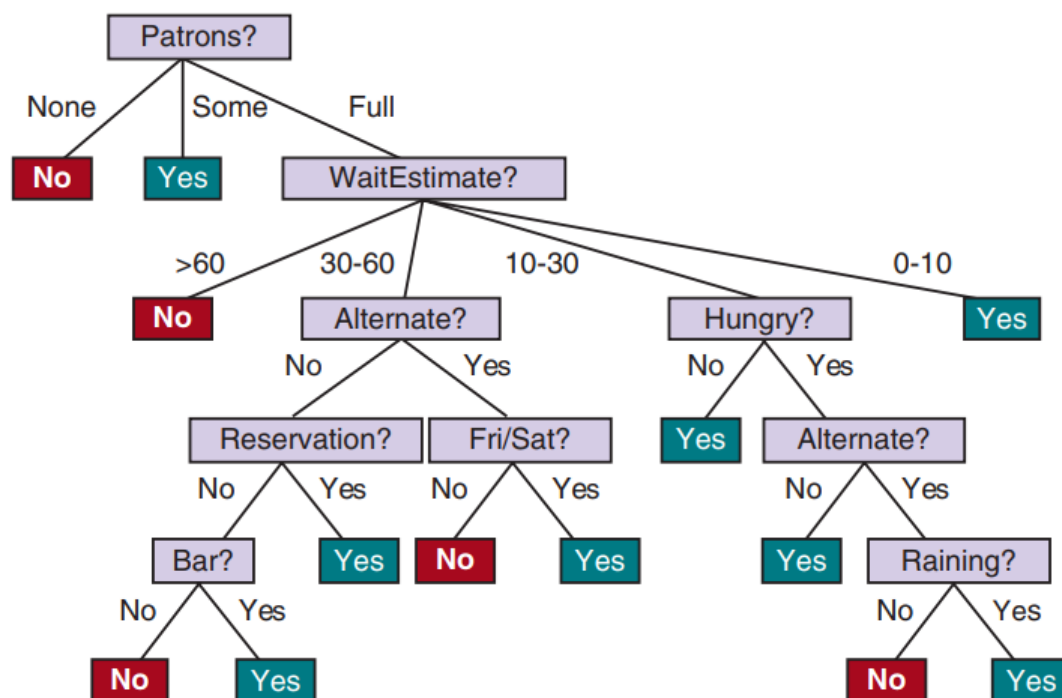
2.2 Przykładowe algorytmy uczenia maszynowego

2.2.1 Drzewa decyzyjne i lasy losowe

Jedną z najprostszych reprezentacji procesu podejmowania decyzji są drzewa decyzyjne (ang. *decision tree*). Przedstawiają one drzewa, czyli spójny, nieskierowany, acykliczny graf, którego wierzchołki przedstawiają pewien test, a liście są decyzjami. Decyzja jest zatem uzyskiwana dzięki wykonaniu szeregu testów na danych wejściowych, aż do momentu dojścia do liścia [4]. Rysunek 2.2 przedstawia wizualną reprezentację drzewa decyzyjnego.

W procesie uczenia algorytm stosuje zazwyczaj zachłannie metodę dziel i zwyciężaj. Jako pierwsze do testów używa się wartości, które mają największy wpływ na klasyfikację, czyli dają największy przyrost informacji [4]. Można to obliczyć przy pomocy entropi Shannona lub Ginni index. Najpowszechniej stosowane algorytmy tworzące drzewa decyzyjne to ID3, C4.5 oraz CART [4, 19].

Drzewa decyzyjne są jednak bardzo skłonne do nadmiernego dopasowania. W procesie uczenia drzewo może stworzyć tyle wierzchołków, że będzie w stanie przypisać każdą wartość w zbiorze treningowym do osobnego liścia. Taki model nie będzie



Rysunek 2.2: Przykładowe binarne (posiada tylko dwie możliwe decyzje) drzewo decyzyjne. Wierzchołki, oznaczone kolorem fioletowym, reprezentują testy. Przy krawędziach zaznaczono wynik testu, który powoduje jej wybranie. Liście, czyli decyzje, są oznaczone kolorem niebieskim – Tak (Yes) oraz czerwonym – Nie (No).
Źródło: [4]

w stanie generalizować, co doprowadzi do złych wyników dla nowych danych. Rozwiązaniem tego problemu jest proces zwany przycinaniem drzewa (ang. *pruning*). Działa on na zasadzie usuwania wierzchołków, których dziećmi są tylko liście, i które nie są statystycznie znaczące [4].

Dużą zaletą drzew decyzyjnych jest prostota ich interpretacji, bardzo łatwo jest je przedstawić wizualnie. Można je stosować zarówno do regresji, jak i do klasyfikacji, potrafią nawet przypisywać kilka klas dla jednego wektora wejściowego. Dodatkowo są one w stanie dopasować się do dużych zbiorów, nie potrzebują normalizacji oraz są stosunkowo szybkie. Główną wadą drzew decyzyjnych jest jednak ich niestabilność. Małe różnice w danych wejściowych mogą prowadzić do dużych zmian w finalnej strukturze drzewa oraz wynikach, które dają [19].

Jednym ze sposobów zmniejszenia wariancji jest stworzenie wielu modeli i podejmowanie decyzji na podstawie ich odpowiedzi, jest to tak zwane ensemble learning. Wyniki są zazwyczaj uśredniane lub przeprowadza się głosowanie, w którym ostateczną odpowiedzią jest ta, którą zwraca największa liczba drzew [4]. W przypadku drzew decyzyjnych takie podejścia nazywa się lasami losowymi (ang. *random forest*). Każde z drzew w procesie wyboru nie bierze pod uwagę wszystkie n atrybutów a je-

dynie pewną ich część, zazwyczaj \sqrt{n} . Nadal wybierany jest ten atrybut, który daje jak największy przyrost informacji [4].

Popularne są również extremely randomized trees (ExtraTrees), które dodają kolejny element losowości. Zamiast szukać wartości progowej, która daje największy przyrost informacji, jest ona wybierana z rozkładu jednostajnego danego atrybutu [4].

2.2.2 Maszyna wektorów nośnych

Maszyny wektorów nośnych, w skrócie SVM (ang. *Support Vector Machine*), to rodzina algorytmów uczenia maszynowego służąca do klasyfikacji oraz regresji. W procesie uczenia algorytm tworzy granice (ang. *decision boundary*), będące hiperpłaszczyznami, w taki sposób, aby ich odległość od punktów była jak największa. Następnie na ich podstawie zwracany jest wynik [4].

Podstawowa wersja SVM opiera się na regresji liniowej. Można ją opisać wzorem:

$$y = w^\top x + b,$$

gdzie \top oznacza transpozycję, b to bias, który zawsze wynosi 1, x jest wektorem danych wejściowych, a w^\top jest wektorem wag, które są zmieniane w trakcie nauki [18].

Maszyny wektorów nośnych pozwalają również na tworzenie modeli nieliniowych dzięki tak zwanemu kernel trick. Wynika on z możliwości algorytmów uczenia maszynowego, które mogą być napisane wyłącznie jako iloczyny skalarne między przykładami. Dzięki temu powyższa liniowa funkcja może być zapisana jako:

$$w^\top x + b = b + \sum_{i=1}^m \alpha_i x^\top x^{(i)},$$

gdzie α jest wektorem wag, a $x^{(i)}$ przykładem treningowym. Następnie x może być zamienione na wynik funkcji $\phi(x)$, a iloczyn skalarny na funkcję $k(x, x^{(i)}) = \phi(x)^\top \phi(x^{(i)})$, nazywaną kernelem. Daje to ostateczną funkcję [18]:


$$f(x) = b + \sum_i \alpha_i k(x, x^{(i)}).$$

Istnieje wiele kerneli, jednym z najpopularniejszych jest radial basis function (RBF). Ma on następujący wzór:

$$k(u, v) = \mathcal{N}(u - v; 0, \sigma^2 I)$$

gdzie $\mathcal{N}(x; \mu, \Sigma)$ oznacza funkcję gęstości prawdopodobieństwa rozkładu normalnego. Wartość funkcji maleje w przestrzeni v wraz z oddalaniem się od punktu u [18]. Rysunek 2.3 przedstawia hiperpłaszczyzny uzyskane przez różne kernele.

Jedną z głównych zalet SVM jest to, że wagi α wynoszą 0 z wyjątkiem wektorów wzmacniających (ang. *support vectors*), które są punktami najbliższymi obliczonym hiperpłaszczyznom. Pozwala to na przyspieszenie obliczeń i ograniczenie zużycia pamięci. Mimo to maszyny wektorów nośnych znacząco tracą na wydajności w przypadku dużych zbiorów danych [4, 18].



Rysunek 2.3: Wizualna reprezentacja granic wygenerowanych przez SVM wykorzystujące różne kernele. Źródło: <https://scikit-learn.org/stable/modules/svm.html> (dostęp 26.05.2023).


2.3 Sztuczne sieci neuronowe

Budowa ludzkiego mózgu oraz sposób działania komórek nerwowych stały się źródłem inspiracji do stworzenia systemów, które potrafiłyby się uczyć. Doprowadziło to do stworzenia modeli zwanych dzisiaj sieciami neuronowymi [4].

2.3.1 Głębokie sieci neuronowe

Współcześnie najpopularniejszym rodzajem sieci neuronowych są tak zwane sieci głębokie, których nazwa pochodzi od wykorzystywania wielu warstw w modelu. Składają się one z neuronów, które imitują działanie biologicznych komórek nerwowych. Każdy neuron otrzymuje sygnały od wielu innych neuronów oraz sam generuje sygnał po przekroczeniu pewnej wartości. Neurony są grupowane w warstwy, które można traktować jako osobne funkcje. Liczbę neuronów w warstwie nazywa się szerokością modelu, a ilość warstw w modelu głębokością. Sieć jest zatem złożeniem funkcji: $f(x) = f^{(3)}(f^{(2)}(f^{(1)}(x)))$, gdzie $f^{(1)}$ oznacza pierwszą warstwę, $f^{(2)}$ drugą itd. Pierwsza warstwa $f^{(1)}$ jest nazywana warstwą wejściową, ostatnia warstwa $f^{(n-1)}$ to warstwa wyjściowa, pozostałe nazywane są warstwami ukrytymi [18].

Sieci zazwyczaj są jednokierunkowe (ang. *feedforward neural networks*). Przepływ sygnałów odbywa się tylko od warstwy wejściowej, poprzez warstwy ukryte, aż do warstwy wyjściowej. Rysunek 2.4 zawiera wizualną reprezentację takiej sieci. Sieci, w których sygnały (końcowy wynik lub wyniki z warstw ukrytych) przesyłane są w obie strony nazywa się sieciami rekurencyjnymi [18].



Rysunek 2.4: Przykładowa jednokierunkowa sieć składająca się z siedmiu warstw. Kwadraty po lewej stronie oznaczają neurony warstwy wejściowej, wyjściem jest pojedynczy neuron po prawej stronie. Źródło: [4].

2.3.2 Funkcje aktywacji

Wartość, jaką neuron przekazuje do kolejnej warstwy, można wyrazić następującym wzorem:

$$a_j = g_j(\sum_i w_{i,j} a_i),$$


gdzie a_j oznacza neuron j , $w_{i,j}$ wagę połączenia między neuronem i oraz j , natomiast g_j to nieliniowa funkcja aktywacji. Nieliniowość pozwala na odwzorowanie dowolnej funkcji przez wystarczająco skomplikowaną sieć [4].

Do najpopularniejszych funkcji aktywacji należą [4]:

- ReLU (rectified linear unit): $ReLU(x) = \max(0, x)$,
- sigmoid (logistic function): $\sigma(x) = 1/(1 + e^{-x})$,
- tangens hiperboliczny: $\tanh(x) = \frac{e^{2x}-1}{e^{2x}+1}$.

2.3.3 Gradient descent

Za uczenie sieci neuronowych odpowiadają algorytmy oparte na metodzie gradientu prostego (ang. *gradient descent*). Metoda ta pozwala na znalezienie lokalnego minimum w przestrzeni dzięki wykonywaniu małych kroków w jego kierunku. Na początku wybiera się losowo punkt należący do danej przestrzeni, następnie oblicza się gradienty i przesuwa w kierunku największego spadku, aż do momentu dojścia do punktu z minimalną wartością funkcji straty (ang. *loss function* lub *cost function*). Odległość o jaką przesuwany jest punkt nazywa się learning rate [4]. Rysunek 2.5 przedstawia działanie algorytmu.



Rysunek 2.5: Wizualizacja przykładowego działania metody gradient descent. Po lewej stronie algorytm znajduje minimum lokalne, po prawej stronie algorytm natrafia na bardzo małe spadki i może zostać zatrzymany przed znalezieniem globalnego minimum. Źródło: [3].

Pojedynczy krok algorytmu można zatem zapisać następująco:

$$w \leftarrow w - \alpha \nabla_w L(w),$$

gdzie w to parametry sieci, α to learning rate, L to funkcja straty [4].

W klasyfikacji jako funkcja straty często stosowana jest entropia krzyżowa (ang. *cross-entropy loss*). Jej ogólny wzór wygląda następująco:

$$H(P, Q) = \int P(x) \log Q(x) dx,$$

gdzie P oznacza prawdziwe wartości zbioru testowego $P^*(x, y)$, a Q wartości przewidziane przez model $P_w(y|x)$. Celem uczenia jest zmiana w tak, aby zminimalizować $H(P^*(x, y), P_w(y|x))$ [4].

Często stosowany jest szybszy wariant algorytmu gradientu prostego zwany stochastic gradient descent, w skrócie SGD. W odróżnieniu od zwykłego algorytmu, w każdej iteracji losowo wybierana jest niewielka liczba wartości, zamiast całego zbioru treningowego. Pozwala to na znaczne przyspieszenie obliczeń [4].

Innym popularnym algorytmem jest Adam, którego nazwa pochodzi od wyrażenia adaptive moments. W trakcie działania Adam dynamicznie zmienia learning rate oraz momentum. Momentum sprawia, że punkt dodatkowo przesuwa się w kierunku opartym na średniej ruchomej poprzednich przesunięć [18].

2.4 Podsumowanie

W tym rozdziale wprowadzono i opisano podstawowe pojęcia związane z uczeniem maszynowym. Następnie przedstawiono problemy związane z pojemnością modeli: niedouczenie i przeuczenie. Przedstawiono również dokładniej sposób działania dwóch popularnych algorytmów: maszyn wektorów nośnych oraz drzew decyzyjnych. Dalej skupiono się na sieciach neuronowych, ich strukturze, funkcjach aktywacji i sposobie uczenia, czyli metodzie gradient descent.

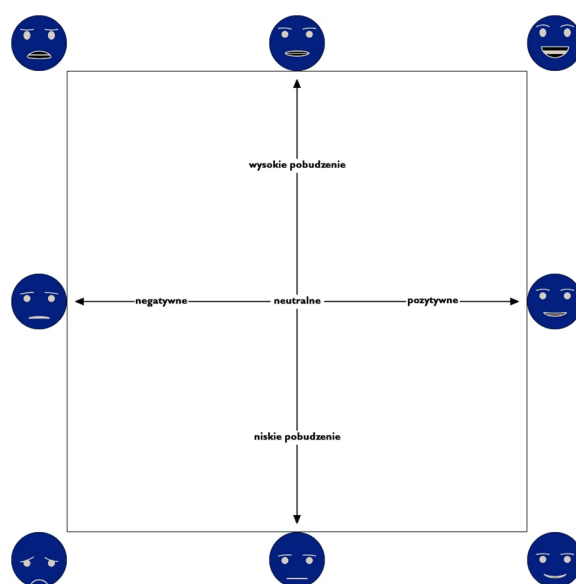
W kolejnym rozdziale stworzony zostanie system wykorzystujący powyższe algorytmy: maszyny wektorów nośnych, drzewa decyzyjne oraz sieci neuronowe, którego celem będzie predykcja emocji na podstawie sygnałów EKG, EDA i ich połączenia.

Rozdział 3

Część praktyczna

3.1 Zbiór danych

W pracy wykorzystano gotowy zbiór danych o nazwie BIRAFFE2 [20]. Zawiera on zapisy elektrokardiografii (EKG), reakcji skórno-galwanicznej (EDA), wyrazów twarzy i ruchu dłoni, które zostały nagrane podczas prób wywołania emocji przez stymulanty audiowizualne i specjalnie przygotowane gry komputerowe. Dodatkowo w zbiorze zawarto subiektywną ocenę stymulantów w dwuwymiarowej przestrzeni przyjemności i pobudzenia (ang. *valence*, *arousal*), wyniki testu osobowości opartego o tak zwaną wielką piątkę (ang. *big five*) oraz ankiety o doświadczeniu z grami komputerowymi. Dane pochodzą od 102 osób w wieku od 18 do 26 lat, z czego 33% badanych to kobiety [20]. Rysunek 3.1 przedstawia widżet, który wykorzystano do uzyskania wartości przyjemności i pobudzenia.



Rysunek 3.1: Widżet użyty do subiektywnej oceny stymulantów. Źródło: [20]

Stymulanty audiowizualne prezentowane były w dwóch turach, z sesją gry komputerowej pomiędzy nimi. Każdy stymulant prezentowany był przez 6 sekund, po czym badany miał 6 sekund na ocenę wywołanych emocji i następowało kolejne 6 sekund przerwy [20]. Wizualne stymulanty wybrano ze zbioru IAPS [21], a dźwiękowe ze zbioru IADS [22].

W niniejszej pracy wykorzystano jedynie zapisy EKG oraz EDA z obu tur prezentacji stymulantów.

3.2 Przygotowanie danych

3.2.1 Oczyszczanie i ekstrakcja cech

Cały system automatycznej predykcji emocji, opisany w tej pracy, został napisany w języku Python. Aby oczyścić dane i dokonać ekstrakcji cech (ang. *feature extraction*) użyto biblioteki NeuroKit¹ [23]. Zawiera ona wiele funkcji i narzędzi pozwalających na pracę z sygnałami biofizycznymi.

Dane zostały podzielone na okienka o długości 18 sekund, co odpowiada pojawieniu się pojedynczego stymulanta audiowizualnego, czasu na subiektywną ocenę emocji oraz przerwie przed kolejnym stymulantem. Wartości odpowiadające treningowi nie były brane pod uwagę.

Sygnały EKG były poddawane oczyszczaniu funkcją `ecg_clean()` z wykorzystaniem metody zaproponowanej przez Pana i Tompkinsa [24]. Następnie znajdowano załamki R w zespole QRS, wykorzystując metodę zaproponowaną w tym samym artykule oraz funkcję `ecg_peaks()`. Na ich podstawie obliczano średnią częstotliwość występowania załamek funkcją `ecg_rate()` oraz wartości związane ze zmiennością rytmu zatokowego (ang. *heart rate variability, HRV*) stosując `hrv_time()` oraz `hrv_frequency()`.

Podobnie jak EKG, sygnał EDA był na początku oczyszczany i wydzielono z niego tonic component, użyto do tego funkcję `eda_process()`. Następnie obliczono ilość wystąpień reakcji oraz ich średnią amplitudę wykorzystując funkcję `eda_intervalrelated()`. Kolejnym krokiem było obliczenie standardowego odchylenia dla tonic component. Następnie wykorzystano `eda_sympathetic()` aby uzyskać wartości związane z sympathetic component, czyli sygnałem w zakresie 0,0045 - 0,25 Hz [25]. Na koniec obliczono autokorelację sygnału stosując `eda_autocorr()`.

W kolejnym kroku zastosowano powyższe metody dla sygnałów z przedziału od pierwszego do ostatniego stymulanta, które potraktowano jako średnią wartość, unikalną dla każdego badanego. Następnie odejmowano wartości uzyskane w każdym z okienek od średniej danej osoby. Miało to na celu uzyskanie danych o zmianie stanu badanego podczas oglądania stymulanta względem normy.

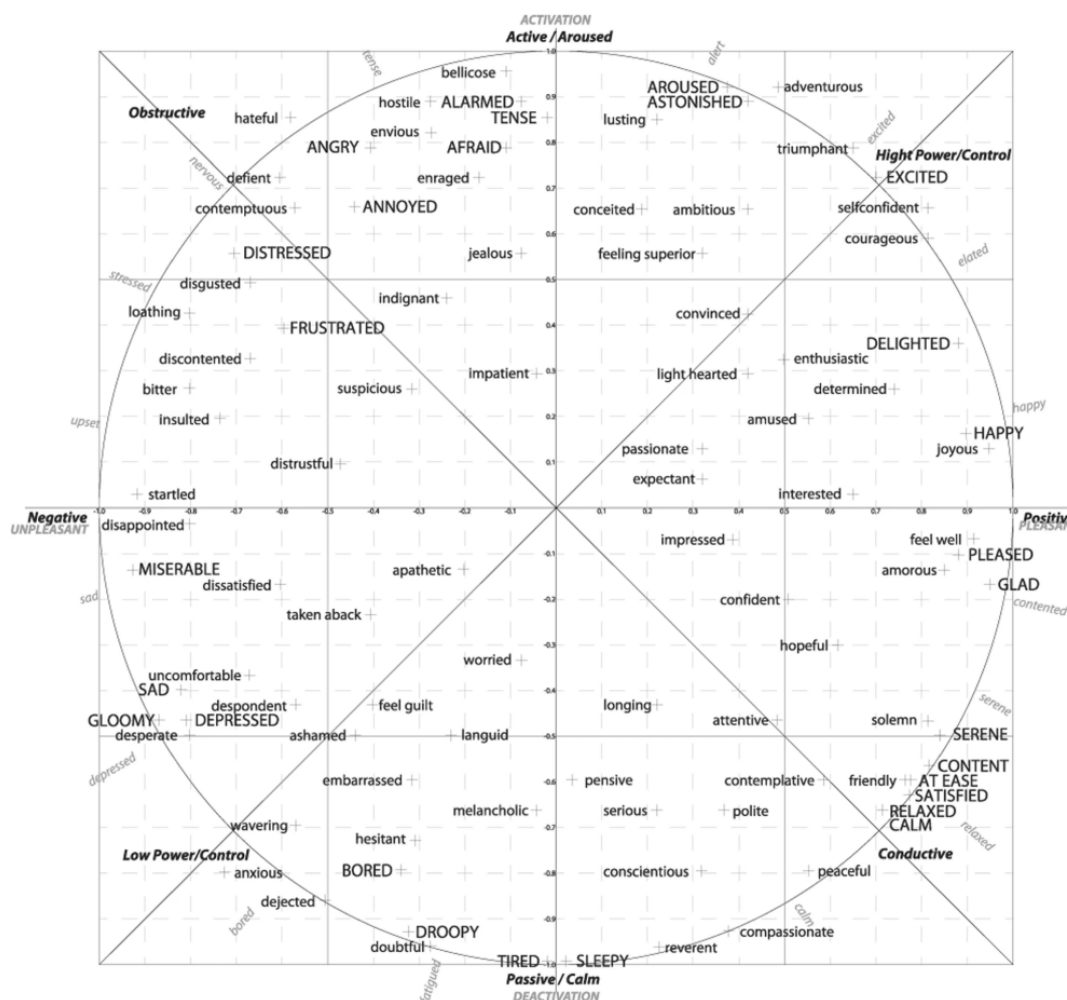
¹<https://neuropsychology.github.io/NeuroKit/>

Dla każdego okienka przypisano odpowiadające mu dwie wartości uzyskane przez subiektywną ocenę. Były to przyjemność emocji (ang. *valence*) oraz pobudzenie (ang. *arousal*) jakie wywołały.

3.2.2 Grupowanie

Po uzyskaniu cech przeprowadzono proces grupowania (ang. *clustering*), w celu zmiany problemu z regresji do klasyfikacji dla kilku klas. Wykorzystano do tego algorytm K-Means, który jest przykładem uczenia nienadzorowanego i został zaproponowany przez Lloyda [26]. Sama użyta funkcja `KMeans()` pochodzi z biblioteki `scikit-learn`² [27].

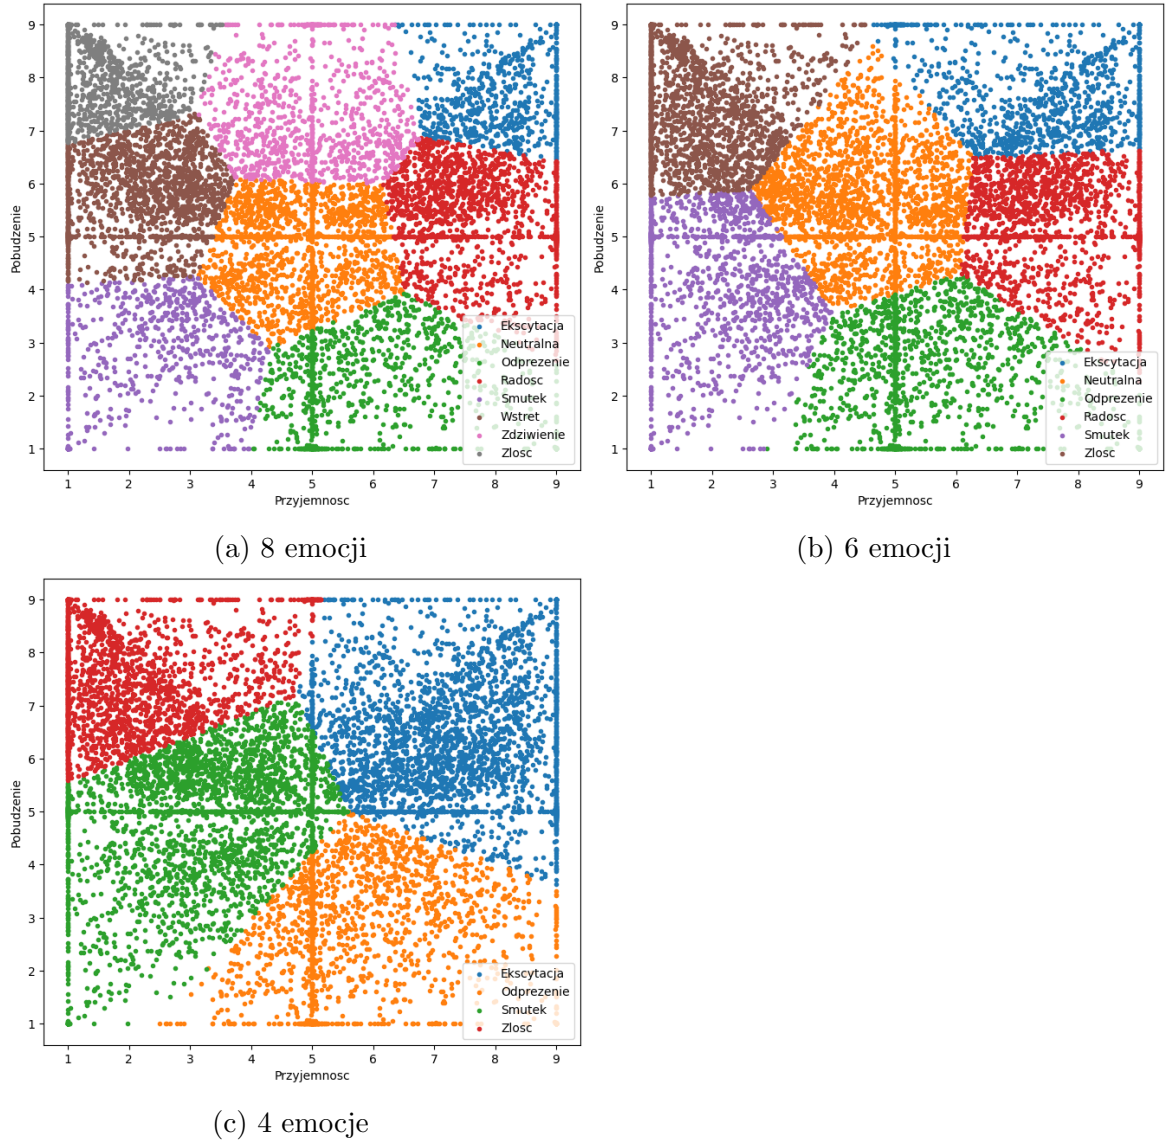
Po obliczeniu centroidów oraz uzyskaniu grup ręcznie przypisano im emocje na podstawie modelu kołowego z [28], przedstawionego na obrazku 3.2.



Rysunek 3.2: Model kołowy użyty do przypisania emocji do grup. Źródło: [28]

²<https://scikit-learn.org/>

W pracy stworzono modele dla ośmiu, sześciu i czterech emocji. Rysunek 3.3 przedstawia pozyskane grupy.



Rysunek 3.3: Uzyskane grupy i przypisane im emocje.

3.3 Wyniki

Do predykcji emocji wykorzystano trzy algorytmy: maszyny wektorów nośnych (SVM), lasy losowe (RFC) oraz sieć neuronową (NN). Dla dwóch pierwszych użyto implementacji dostępnych w scikit-learn, odpowiednio `SVC()` i `RandomForestClassifier()`. W przypadku sieci neuronowej wykorzystano natomiast bibliotekę TensorFlow³ [29].

³<https://tensorflow.org/>

Stworzono stosunkowo prostą wielowarstwową jednokierunkową sieć neuronową, składającą się z gęstych warstw (ang. *dense layer*), czyli wszystkie neurony w warstwie były połączone ze wszystkimi neuronami w kolejnej warstwie. Jako funkcję aktywacji wykorzystano ReLU, a do nauki użyto SGD z momentum.

Dane wejściowe były skalowane wykorzystując `StandardScaler()` z scikit-learn, tak aby każda cecha posiadała średnią równą 0 oraz odchylenie standardowe równe 1. Następnie dzielono dane na zbiór treningowy oraz zbiór testowy. Zbiór testowy zawierał 10% losowo wybranych wartości. Sieć neuronowa wymagała dodatkowo zbioru walidacyjnego, który również zawierał 10% losowo wybranych wartości.

Do oceny wyników modeli wykorzystano trzy miary. Pierwsza z nich, *accuracy*, mówi o tym ile wartości zostało sklasyfikowanych poprawnie [18]. Pozostałe są oparte o tak zwany F-score lub F_1 , który opiera się na dwóch miarach. *Precision*, które opisuje, ile razy model zaklasyfikował przykład poprawnie, czyli ile razy nie popełnił błędu. *Recall*, mówiące o tym ile wartości sklasyfikowano jako poprawne, co można interpretować jako umiejętność znalezienia wszystkich poprawnych wartości. F_1 można natomiast opisać wzorem: $F = \frac{2pr}{p+r}$, gdzie p to *precision*, a r to *recall* [18].

Miary te można jednak obliczać jedynie dla klasyfikatorów binarnych. W przypadku przewidywania wielu klas, oblicza się F_1 osobno dla każdej. Następnie można stosować wiele podejść. W *Macro F_1* uzyskuje się średnią z wartości wszystkich klas. *Weighted F_1* bierze dodatkowo pod uwagę *Support*, czyli ilość wystąpień klasy w zbiorze. Pozwala to na lepsze oszacowanie zbiorów, w których ilość klas nie jest równa.

3.3.1 Elektrokardiografia

Po wykonaniu powyższych kroków wybrano wartości związane z elektrokardiografią oraz zmiennością rytmu zatokowego, co dało 29 cech. Następnie dane ze zbiorów treningowych zostały przetworzone przez algorytmy. Na koniec sprawdzono ich skuteczność na zbiorach treningowych. Tabela 3.1 zawiera uzyskane wyniki.

Ilość emocji	Model	Accuracy	Macro F_1	Weighted F_1
Cztery	SVM	0.3113	0.1249	0.1547
	RFC	0.3340	0.2743	0.2988
	NN	0.3283	0.1390	0.1763
Sześć	SVM	0.2346	0.0690	0.0938
	RFC	0.2763	0.2113	0.2389
	NN	0.2857	0.2003	0.2363
Osiem	SVM	0.1892	0.0442	0.0646
	RFC	0.2223	0.1601	0.1928
	NN	0.2403	0.1592	0.2007

Tabela 3.1: Wyniki systemu opartego na sygnale EKG.

Dla czterech i sześciu emocji najlepszym modelem były lasy losowe, natomiast dla ośmiu emocji lepsze wyniki osiągnęła sieć neuronowa. Najgorszym modelem we wszystkich testach jest SVM, który jest również najmniej skomplikowany, przez co nie posiada on wystarczającej pojemności dla tak złożonych danych.

3.3.2 Reakcja skórno-galwaniczna

Podobnie do EKG, po wyodrębnieniu cech związanych z reakcją skórno-galwaniczną uzyskano ich 11. Tabela 3.2 zawiera uzyskane wyniki.

Ilość emocji	Model	Accuracy	Macro F_1	Weighted F_1
Cztery	SVM	0.3113	0.1187	0.1478
	RFC	0.3141	0.2848	0.3016
	NN	0.3132	0.2032	0.2450
Sześć	SVM	0.2337	0.0631	0.0885
	RFC	0.2886	0.2384	0.2672
	NN	0.2621	0.1418	0.1790
Osiem	SVM	0.1892	0.0432	0.0643
	RFC	0.2233	0.1828	0.2105
	NN	0.2241	0.1335	0.1935

Tabela 3.2: Wyniki systemu opartego o reakcję skórno-galwaniczną.

Wyniki są bardzo zbliżone do tych uzyskanych przez systemy bazujące na elektrokardiografii. Lasy losowe oraz sieć neuronowa osiągnęły podobne wyniki, natomiast maszyna wektorów nośnych jest znacząco gorsza. Dla czterech emocji najlepszy model (RFC) uzyskał gorsze accuracy niż system EKG, ale F_1 były lepsze dla systemu opartego o EDA. W przypadku sześciu i ośmiu emocji lepszy okazał się algorytm rozpoznający emocje na podstawie reakcji skórno-galwanicznej.

3.3.3 System wielomodalny

Na koniec stworzono modele, oparte o cechy zarówno z EKG, jak i z EDA, tworząc system wielomodalny. Uzyskano dzięki temu 40 cech. Tabela 3.3 przedstawia wyniki systemu wielomodalnego.

Dla czterech i ośmiu cech lepsze wyniki uzyskano dzięki zastosowaniu systemu wielomodalnego. Natomiast dla sześciu emocji niewiele lepszy okazał się system oparty o EDA. Nie są to jednak bardzo duże różnice, wynoszą one około 1%. Tak jak w systemach jednomodalnych, SVM dawały najgorsze wyniki, a lasy losowe oraz sieci neuronowe były do siebie zbliżone. Dla najbardziej skomplikowanego przypadku, czyli ośmiu emocji, sieć znowu uzyskała najlepsze wyniki.

Ilość emocji	Model	Accuracy	Macro F_1	Weighted F_1
Cztery	SVM	0.3122	0.1332	0.1641
	RFC	0.3321	0.2848	0.3060
	NN	0.3396	0.2202	0.2643
Sześć	SVM	0.2346	0.0690	0.0938
	RFC	0.2933	0.2297	0.2606
	NN	0.2990	0.2274	0.2591
Osiem	SVM	0.1911	0.0541	0.0783
	RFC	0.2308	0.1810	0.2109
	NN	0.2507	0.1935	0.2252

Tabela 3.3: Wyniki systemu wielomodalnego.

3.4 Podsumowanie wyników

Niestety uzyskane wyniki są stosunkowo niskie. Mimo to nadal są lepsze od losowego wybierania emocji, które wynosiłoby 25% dla czterech emocji, 16,7% dla sześciu i 12,5% dla ośmiu. Złożoność problemu najlepiej obrazują wyniki uzyskane przez prostsze maszyny wektorów nośnych, których F_1 było 2–3 razy gorsze od bardziej skomplikowanych algorytmów. Sygnały biofizyczne dodatkowo komplikują automatyczną predykcję, między innymi przez to, że są one niezależne od woli człowieka, oraz przez różnice między poszczególnymi osobami. Nawet próby wywołania pewnych określonych emocji mogą skutkować odmiennymi reakcjami. W przypadku wyrazu twarzy lub mowy istnieje możliwość sztucznego przedstawiania emocji, lub ich wyolbrzymiania. Nie da się uzyskać takiego efektu dla sygnałów biofizycznych.

Istnieje kilka podejść, które mają potencjał polepszenia wyników. Zbiór danych zawiera zdjęcia wyrazów twarzy, które mogą zostać wykorzystane jako kolejne źródło informacji o stanie emocjonalnym. Mimo że nie są to sztucznie wyrażane emocje, a naturalne reakcje badanych, systemy oparte o wyrazy twarzy uzyskują bardzo dobre wyniki oraz są jednym z najpopularniejszych podejść w automatycznej predykcji stanów emocjonalnych.

Drugą możliwością jest dalsze eksperymentowanie z sieciami neuronowymi. W niniejszej pracy uzyskiwały one najlepsze wyniki dla rozpoznawania ośmiu emocji, co pokazuje ich potencjał w skomplikowanych problemach. Ilość hiperparametrów oraz potencjalne architektury sprawiają, że stworzenie najlepszej sieci neuronowej jest bardzo skomplikowane. Możliwe jest wykorzystanie sieci konwolucyjnych, rekurencyjnych lub residual.

Kolejne podejścia mogą opierać się na wykorzystaniu odmiennego procesu przygotowania danych, na przykład przez ekstrakcję większej ilości cech lub użycie innych algorytmów zarówno do ekstrakcji, jak i uczenia.

Podsumowanie

Automatyczna predykcja emocji staje się coraz bardziej popularnym problemem, który może znaleźć zastosowanie w wielu dziedzinach ludzkiego życia. Od dynamicznie rozwijającej się robotyki, przez naukę, aż po przemysł rozrywkowy, informacja o stanie emocjonalnym ma potencjał usprawnić sposób w jaki prowadzimy interakcje z danymi systemami. W niniejszej pracy przedstawiono podstawy automatycznej predykcji emocji. Zaprezentowano źródła, na podstawie których istnieje możliwość predykcji stanów emocjonalnych. Począwszy od tych, które można odbierać ludzkimi zmysłami, czyli wyrazy twarzy, mowa, gestykulacja, aż po wymagające specjalnej aparatury do odczytu — sygnałów biofizycznych. Następnie przedstawiono możliwości reprezentacji informacji o emocjach w systemach komputerowych, podejścia oparte na wartościach liczbowych, jak i kategoryzacji.

W kolejnej części opisano uczenie maszynowe, które jest przoduującym podejściem w systemach automatycznej predykcji emocji. Zaczęto od przedstawienia podstaw, po czym skupiono się na bardziej szczegółowym opisanu dwóch popularnych algorytmów: maszyn wektorów nośnych oraz lasów losowych. Następnie opisano podstawy sieci neuronowych, które wykazują duży potencjał i są bardzo często wykorzystywane w badaniach nad automatyczną predykcją emocji.

Na koniec zaproponowano kilka modeli, które przewidują emocje na podstawie elektrokardiografii oraz reakcji skórno-galwanicznej ze zbioru BIRAFFE2. Niestety uzyskano wyniki, które nie są zadowalające, co obrazuje, jak skomplikowanym problemem jest próba rozpoznawania emocji, zwłaszcza na podstawie sygnałów biofizycznych. Zaproponowano również podejścia, które mają potencjał poprawy wyników w przyszłości.

Bibliografia

- [1] Ashwini Ann Varghese, Jacob P Cherian, and Jubilant J Kizhakkethottam. Overview on emotion recognition system. In *2015 International Conference on Soft-Computing and Networks Security (ICSNS)*, pages 1–5, 2015. doi:10.1109/ICSNS.2015.7292443.
- [2] Andrius Dzedzickis, Arturas Kaklauskas, and Vytautas Bucinskas. Human emotion recognition: Review of sensors and methods. *Sensors*, 20(3):592, 2020. doi:10.3390/s20030592.
- [3] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O’Reilly Media, Inc., 2019. ISBN 9781492032649.
- [4] Stuart Russell and Peter Norvig. *Artificial Intelligence: A Modern Approach (4th Edition)*. Pearson, 2020. ISBN 9780134610993. URL <http://aima.cs.berkeley.edu/>.
- [5] Rafael Calvo, Sidney D’Mello, Jonathan Gratch, and Arvid Kappas. *The Oxford Handbook of Affective Computing*. Oxford University Press, 01 2015. ISBN 9780199942237. doi:10.1093/oxfordhb/9780199942237.001.0001.
- [6] Erroll Wood, Tadas Baltrusaitis, Charlie Hewitt, Matthew Johnson, Jingjing Shen, Nikola Milosavljevic, Daniel Wilde, Stephan J. Garbin, Toby Sharp, Ivan Stojiljkovic, Tom Cashman, and Julien Valentin. 3d face reconstruction with dense landmarks. *CoRR*, abs/2204.02776, 2022. doi:10.48550/arXiv.2204.02776.
- [7] ByoungChul Ko. A brief review of facial emotion recognition based on visual information. *Sensors*, 18(2):401, 2018. doi:10.3390/s18020401.
- [8] Paul Ekman and Wallace V Friesen. Facial action coding system. *Environmental Psychology & Nonverbal Behavior*, 1978. doi:10.1037/t27734-000.
- [9] Fatemeh Noroozi, Ciprian Adrian Corneanu, Dorota Kaminska, Tomasz Sapinski, Sergio Escalera, and Gholamreza Anbarjafari. Survey on emotional body gesture recognition. *IEEE Trans. Affect. Comput.*, 12(2):505–523, 2021. doi:10.1109/TAFFC.2018.2874986.

- [10] Andrea Kleinsmith and Nadia Bianchi-Berthouze. Affective body expression perception and recognition: A survey. *IEEE Trans. Affect. Comput.*, 4(1):15–33, 2013. doi:10.1109/T-AFFC.2012.16.
- [11] Taiba Majid Wani, Teddy Surya Gunawan, Syed Asif Ahmad Qadri, Mira Kartiwi, and Eliathamby Ambikairajah. A comprehensive review of speech emotion recognition systems. *IEEE Access*, 9:47795–47814, 2021. doi:10.1109/ACCESS.2021.3068045.
- [12] Mohammed Abdel-Wahab and Carlos Busso. Evaluation of syllable rate estimation in expressive speech and its contribution to emotion recognition. In *2014 IEEE Spoken Language Technology Workshop, SLT 2014, South Lake Tahoe, NV, USA, December 7-10, 2014*, pages 472–477. IEEE, 2014. doi:10.1109/SLT.2014.7078620.
- [13] João Paulo Teixeira, Carla Oliveira, and Carla Lopes. Vocal acoustic analysis – jitter, shimmer and HNR parameters. *Procedia Technology*, 9:1112–1122, 2013. ISSN 2212-0173. doi:https://doi.org/10.1016/j.protcy.2013.12.124.
- [14] Paul Ekman. Universals and cultural differences in facial expressions of emotion. In *Nebraska symposium on motivation*. University of Nebraska Press, 1971.
- [15] Shan Li, Weihong Deng, and Junping Du. Reliable crowdsourcing and deep locality-preserving learning for expression recognition in the wild. In *2017 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2017, Honolulu, HI, USA, July 21-26, 2017*, pages 2584–2593. IEEE Computer Society, 2017. doi:10.1109/CVPR.2017.277.
- [16] James A Russell. A circumplex model of affect. *Journal of personality and social psychology*, 39(6):1161, 1980. doi:10.1037/h0077714.
- [17] Sidney K. D’Mello and Jacqueline M. Kory. Consistent but modest: a meta-analysis on unimodal and multimodal affect detection accuracies from 30 studies. In Louis-Philippe Morency, Dan Bohus, Hamid K. Aghajan, Justine Cassell, Anton Nijholt, and Julien Epps, editors, *International Conference on Multimodal Interaction, ICMI ’12, Santa Monica, CA, USA, October 22-26, 2012*, pages 31–38. ACM, 2012. doi:10.1145/2388676.2388686.
- [18] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. URL deeplearningbook.org.
- [19] Kevin P. Murphy. *Probabilistic Machine Learning: An introduction*. MIT Press, 2022. URL probml.ai.

- [20] Krzysztof Kutt, Dominika Drążyk, Laura Żuchowska, Maciej Szelażek, Szymon Bobek, and Grzegorz J Nalepa. BIRAFFE2, a multimodal dataset for emotion-based personalization in rich affective game environments. *Scientific Data*, 9(1): 274, 2022. doi:<https://doi.org/10.1038/s41597-022-01402-6>.
- [21] Peter J Lang, Margaret M Bradley, Bruce N Cuthbert, et al. International affective picture system (IAPS): Affective ratings of pictures and instruction manual. 2005.
- [22] Margaret M Bradley and Peter J Lang. The international affective digitized sounds (IADS-2): Affective ratings of sounds and instruction manual. 2007.
- [23] Dominique Makowski, Tam Pham, Zen J. Lau, Jan C. Brammer, François Lespinasse, Hung Pham, Christopher Schölzel, and S. H. Annabel Chen. NeuroKit2: A python toolbox for neurophysiological signal processing. *Behavior Research Methods*, 53(4):1689–1696, feb 2021. doi:10.3758/s13428-020-01516-y.
- [24] Jiapu Pan and Willis J. Tompkins. A real-time qrs detection algorithm. *IEEE Transactions on Biomedical Engineering*, BME-32(3):230–236, 1985. doi:10.1109/TBME.1985.325532.
- [25] Hugo F Posada-Quintero, John P Florian, Alvaro D Orjuela-Cañón, Tomas Aljama-Corrales, Sonia Charleston-Villalobos, and Ki H Chon. Power spectral density analysis of electrodermal activity for sympathetic function assessment. *Annals of biomedical engineering*, 44:3124–3135, 2016. doi:10.1007/s10439-016-1606-6.
- [26] Stuart P. Lloyd. Least squares quantization in PCM. *IEEE Trans. Inf. Theory*, 28(2):129–136, 1982. doi:10.1109/TIT.1982.1056489.
- [27] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [28] Dimitrios Kollias, Panagiotis Tzirakis, Mihalis A. Nicolaou, Athanasios Papaioannou, Guoying Zhao, Björn W. Schuller, Irene Kotsia, and Stefanos Zafeiriou. Deep affect prediction in-the-wild: Aff-wild database and challenge, deep architectures, and beyond. *Int. J. Comput. Vis.*, 127(6-7):907–929, 2019. doi:10.1007/s11263-019-01158-4.
- [29] Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, Matthieu Devin, Sanjay Ghemawat, Ian Goodfellow, Andrew Harp, Geoffrey Irving, Michael Isard,

Yangqing Jia, Rafal Jozefowicz, Lukasz Kaiser, Manjunath Kudlur, Josh Levenberg, Dandelion Mané, Rajat Monga, Sherry Moore, Derek Murray, Chris Olah, Mike Schuster, Jonathon Shlens, Benoit Steiner, Ilya Sutskever, Kunal Talwar, Paul Tucker, Vincent Vanhoucke, Vijay Vasudevan, Fernanda Viégas, Oriol Vinyals, Pete Warden, Martin Wattenberg, Martin Wicke, Yuan Yu, and Xiaoqiang Zheng. TensorFlow: Large-scale machine learning on heterogeneous systems. 2015. doi:<https://doi.org/10.5281/zenodo.4724125>. URL <https://www.tensorflow.org/>. Software available from tensorflow.org.

Spis rysunków

1.1	Ogólny schemat systemu predykcji emocji	5
1.2	Schemat systemu rozpoznającego emocje na podstawie twarzy. Źródło: [7]	7
1.3	Action Units w trzech częściach twarzy. Źródło: [7]	7
1.4	Sposoby reprezentowania ciała w komputerze: zbiór części ciała (lewa strona) oraz reprezentacja szkieletowa (prawa strona). Źródło: [9]	9
1.5	Sygnał mowy z zaznaczonymi jitter i shimmer. Źródło: [13]	10
1.6	Przykładowy sygnał EKG z zaznaczonymi załamkami. Źródło: [2]	11
1.7	Przykładowy sygnał GSR. Czerwone linie oznaczają momenty pojawiania się stymulantu. Źródło: [2]	12
1.8	Przykładowa baza danych zawierająca zdjęcia twarzy przedstawiające podstawowe emocje. Źródło: [15]	13
1.9	Kołowy model oparty o torię Russella. Źródło: [2]	14
2.1	Wizualna reprezentacja wyników modelu niedouczonego (lewa strona), modelu posiadającego dobry stopień generalizacji (środek) oraz modelu przuczonego (prawa strona). Źródło: [18]	18
2.2	Przykładowe binarne (posiada tylko dwie możliwe decyzje) drzewo decyzyjne. Wierzchołki, oznaczone kolorem fioletowym, reprezentują testy. Przy krawędziach zaznaczono wynik testu, który powoduje jej wybranie. Liście, czyli decyzje, są oznaczone kolorem niebieskim – Tak (Yes) oraz czerwonym – Nie (No). Źródło: [4]	19
2.3	Wizualna reprezentacja granic wygenerowanych przez SVM wykorzystujące różne kernele. Źródło: https://scikit-learn.org/stable/modules/svm.html (dostęp 26.05.2023).	21
2.4	Przykładowa jednokierunkowa sieć składająca się z siedmiu warstw. Kwadraty po lewej stronie oznaczają neurony warstwy wejściowej, wyjściem jest pojedynczy neuron po prawej stronie. Źródło: [4].	22
2.5	Wizualizacja przykładowego działania metody gradient descent. Po lewej stronie algorytm znajduje minimum lokalne, po prawej stronie algorytm natrafia na bardzo małe spadki i może zostać zatrzymany przed znalezieniem globalnego minimum. Źródło: [3].	23
3.1	Widżet użyty do subiektywnej oceny stymulantów. Źródło: [20]	25

3.2	Model kołowy użyty do przypisania emocj do grup. <i>Źródło: [28]</i> . . .	27
3.3	Uzyskane grupy i przypisane im emocje.	28

Spis tabel

3.1	Wyniki systemu opartego na sygnale EKG.	29
3.2	Wyniki systemu opartego o reakcję skórno-galwaniczną.	30
3.3	Wyniki systemu wielomodalnego.	31